PÓS TECH FIAP
TECH CHALLENGE – FASE 2

Prevendo a qualidade do vinho a partir da sua química

Análise exploratória e modelos de classificação com o Wine Quality Dataset

Outubro de 2026

ÍNDICE

I. Compreensão do problema

i. O problema
ii. Propósito do estudo

II. Exploração dos dados

i. Base de dados
ii. Quantidade de vinhos de alta qualidade
iii. Definição da cor do vinho pela base
iv. Tipos de vinho
v. Outliers
vi. Atributos que separam os vinhos bons
vii. Correlação entre atributos

III. Preparação & Modelos

i. Como preparamos o teste
ii. Modelos testados
iii. Modelos com mais acertos
iv. Por que eles se saíram melhor

IV. Conclusões

i. O que mais pesa na qualidade do vinho
ii. Qualidade: combinação de fatores
iii. Sugestões
iv. Finalização



01.
COMPREENSÃO DO PROBLEMA



01 · COMPREENSÃO DO PROBLEMA

Hoje, a qualidade de um vinho depende do paladar — e do tempo — de especialistas

Desvantagens

A avaliação sensorial se torna subjetiva, lenta e dependente da experiência pessoal de quem prova.

Nossa proposta

Usar 11 medidas de laboratório para prever a qualidade antes da prova.

O que é “bom”?

Nota ≥ 7: alta qualidade
Nota < 7: baixa ou média qualidade

01 · COMPREENSÃO DO PROBLEMA

Não pretendemos excluir a avaliação sensorial (humana), mas apoiá-la.

- A nota sensorial depende da experiência de quem prova: o mesmo vinho pode receber notas diferentes de especialistas diferentes. Por isso, cada vinho da base foi avaliado por pelo menos 3 especialistas, e a nota é a mediana entre eles.

- Com Machine Learning, as medidas de laboratório indicam, antes da prova, quais vinhos têm mais chance de serem de alta qualidade, e o especialista decide com essa informação em mãos.

Vinho escolhido → Análise de laboratório → Previsão do modelo → **Avaliação sensorial**

02. EXPLORAÇÃO DOS DADOS



02 · EXPLORAÇÃO DOS DADOS

Uma base enxuta e completa

1.143

amostras de vinho tinto avaliadas por especialistas

11

medidas físico-químicas: acidez, álcool, açúcar, sulfatos, pH...

0

valores faltantes, nenhuma lacuna a preencher

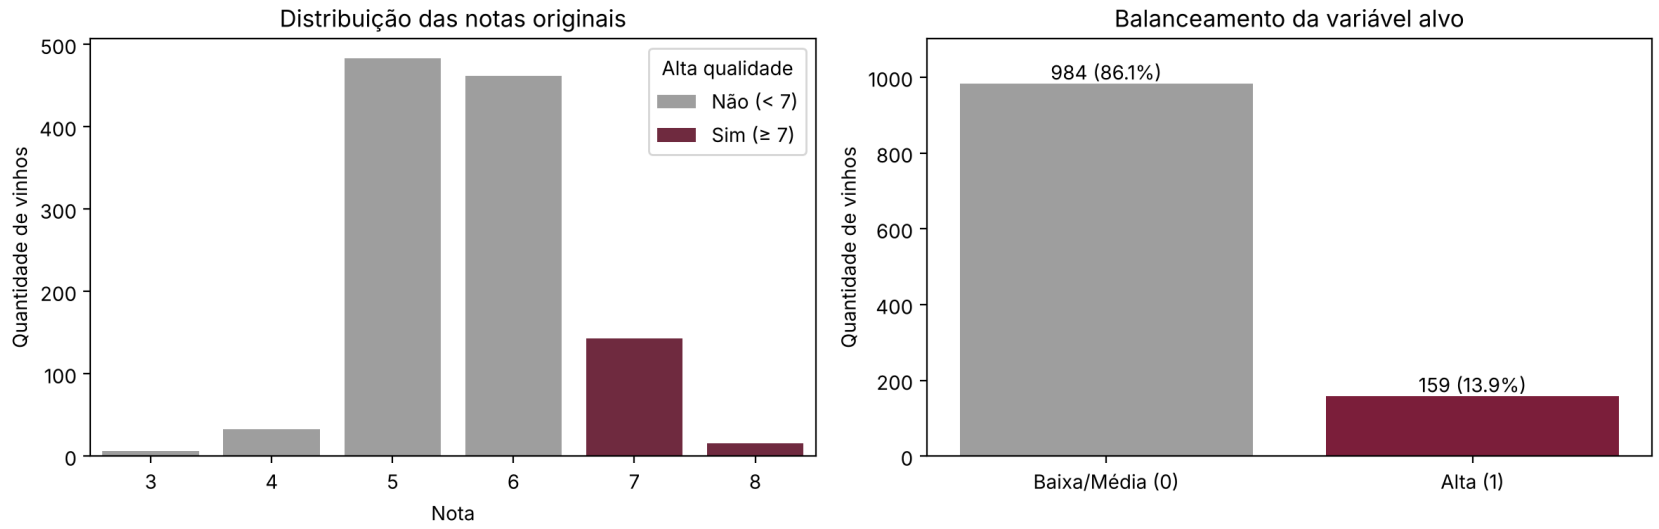
125

amostras com química idêntica a outra (duplicadas)

As notas na base vão de **3 a 8**: nenhum vinho é péssimo, e nenhum é perfeito.

02 · EXPLORAÇÃO DOS DADOS

Só 1 em cada 7 vinhos é de alta qualidade

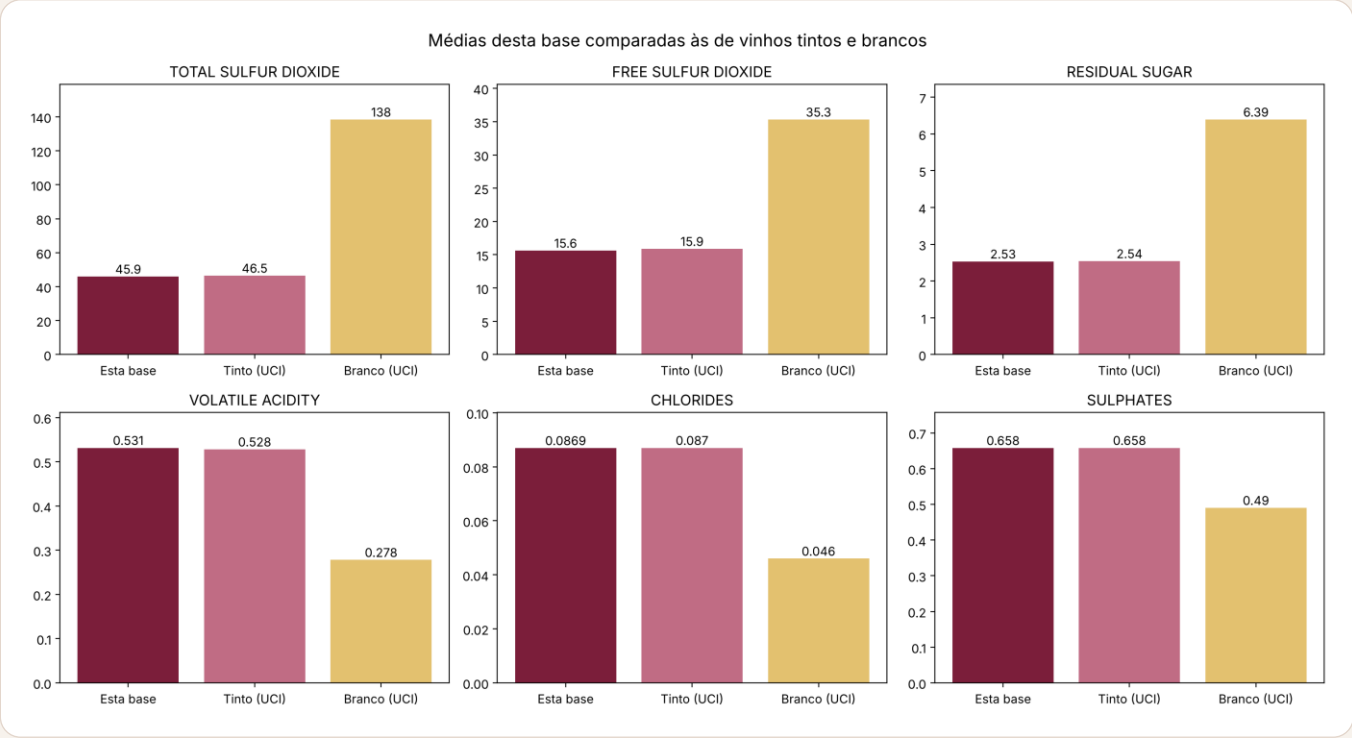


Importante: um modelo que dissesse sempre “não é bom” acertaria 86% das vezes e seria inútil. Por isso medimos o acerto nos vinhos bons e demos mais peso a eles no treino.

Fonte: gráficos do notebook · distribuição das notas e balanceamento do alvo

02 · EXPLORAÇÃO DOS DADOS

A base não diz a cor. Mas a química mostra que são tintos



Dióxido de enxofre total (SO_2)

3× menor que nos brancos: 45,9 mg/L nesta base, 46,5 nos tintos e 138,4 nos brancos.

Por quê?

Tintos precisam de menos SO_2 porque os taninos da casca já agem como antioxidantes.

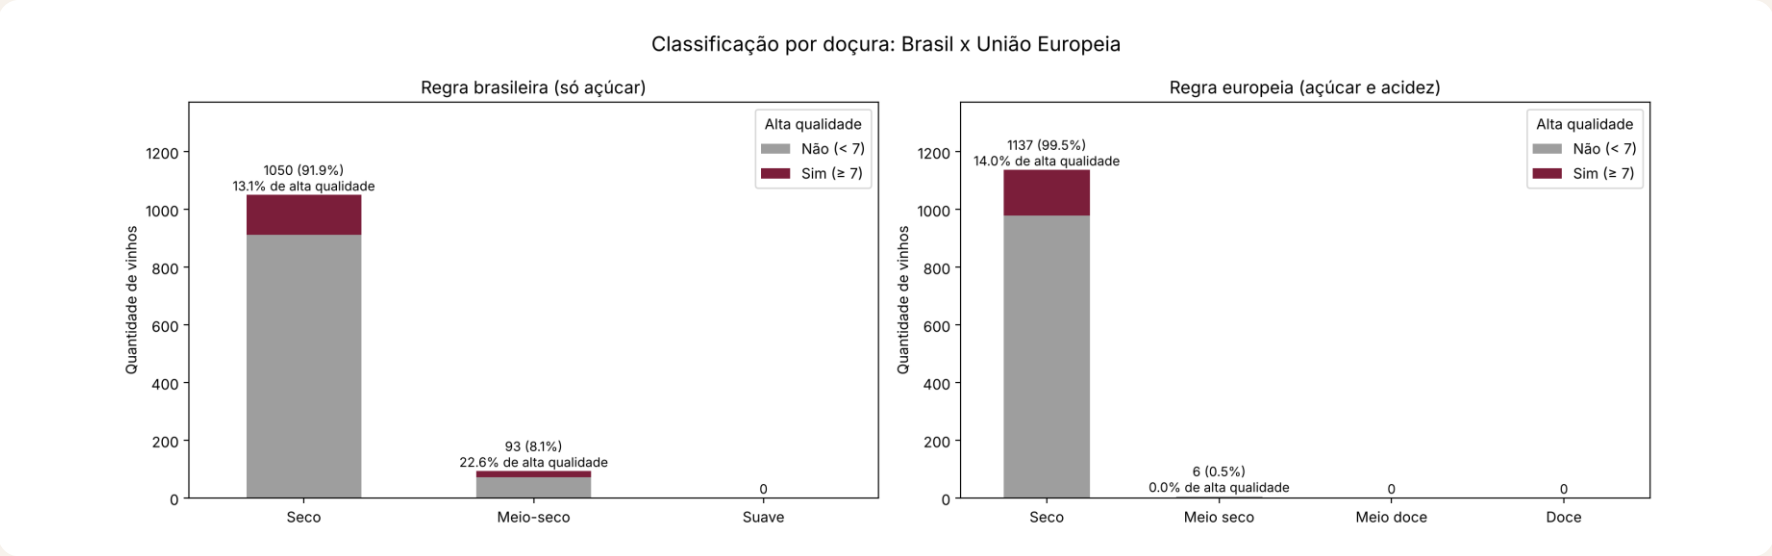
O padrão se repete

Açúcar, SO_2 livre, acidez volátil, cloretos e sulfatos: sempre próximos dos tintos e longe dos brancos.

Referência: médias de tintos e brancos da base original da UCI (Cortez et al., 2009) · as conclusões valem só para vinhos tintos

02 · EXPLORAÇÃO DOS DADOS

Tipo do vinho: pela regra europeia, 99,5% dos vinhos são secos

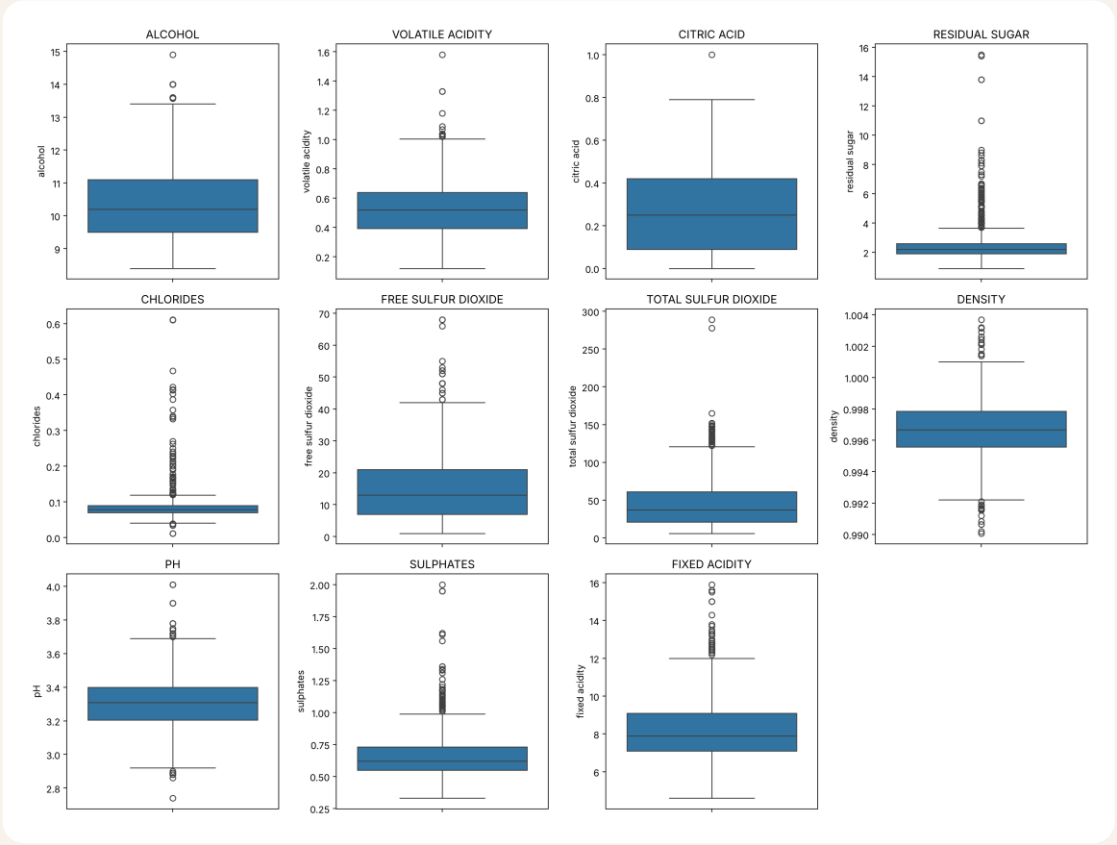


A regra muda a leitura da qualidade. No Brasil, os meio-secos parecem melhores (22,6% contra 13,1%); na UE, os 6 meio secos não têm vinho bom.

Regra de tipo de vinho no Brasil: só o açúcar / União Europeia: açúcar e acidez

02 · EXPLORAÇÃO DOS DADOS

Poucos vinhos fogem do padrão, decidimos mantê-los



Onde estão os outliers (extremos)?

Sal (cloretos) e Açúcar concentram a maioria;
Sulfatos, SO_2 total e Acidez Fixa também têm bastante;
pH e Densidade têm extremos para cima e para baixo;
Álcool e Ácido Cítrico quase não têm.

O que fizemos

Tratamos como variação real entre vinhos e mantivemos todos na base.

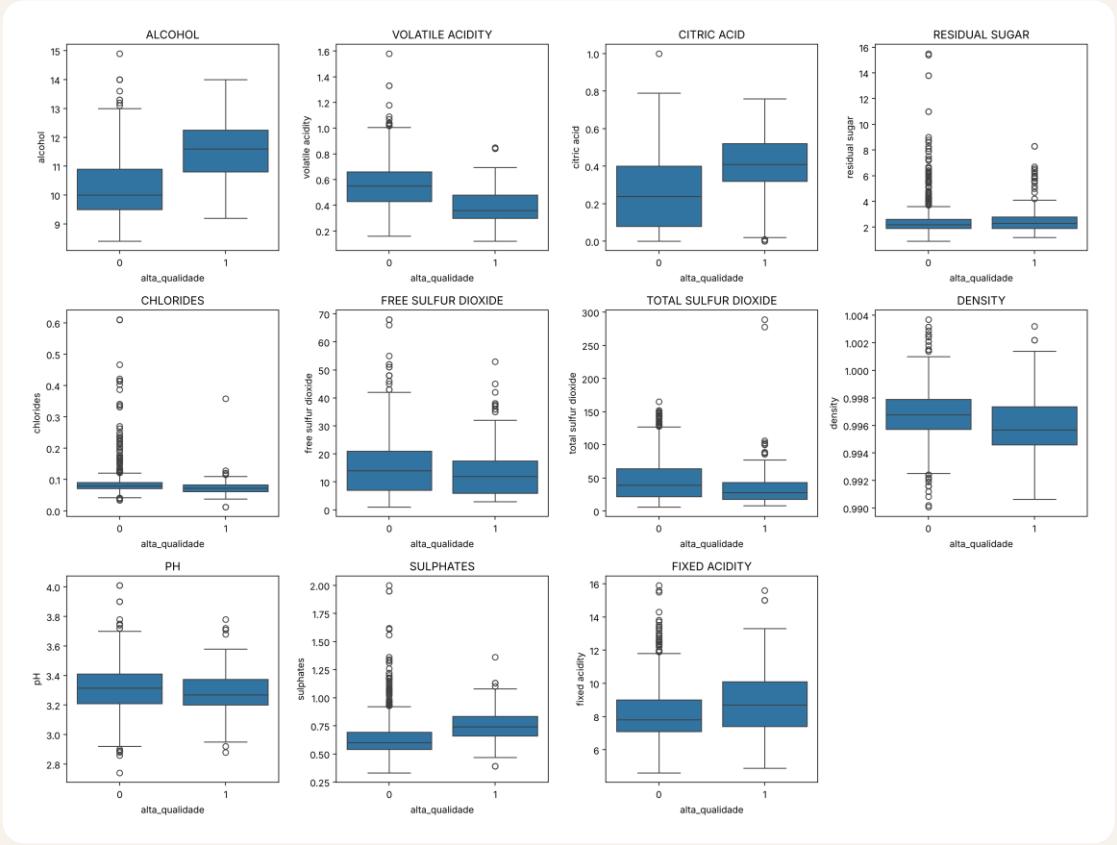
Os outliers atrapalham?

Padronizamos as medidas e escolhemos modelos que lidam bem com extremos, como o Random Forest. E o açúcar, cheio de extremos, nem pesa na qualidade.

Assimetria acima de 1 em 6 das 11 medidas: cloretos, açúcar residual, sulfatos, SO_2 total e livre, acidez fixa

02 · EXPLORAÇÃO DOS DADOS

O que separa um vinho bom de um mediano



↑ Mais álcool
a diferença mais visível entre as caixas

↓ Menos acidez volátil
em excesso, lembra vinagre

↑ Mais ácido cítrico
a caixa dos bons fica bem acima

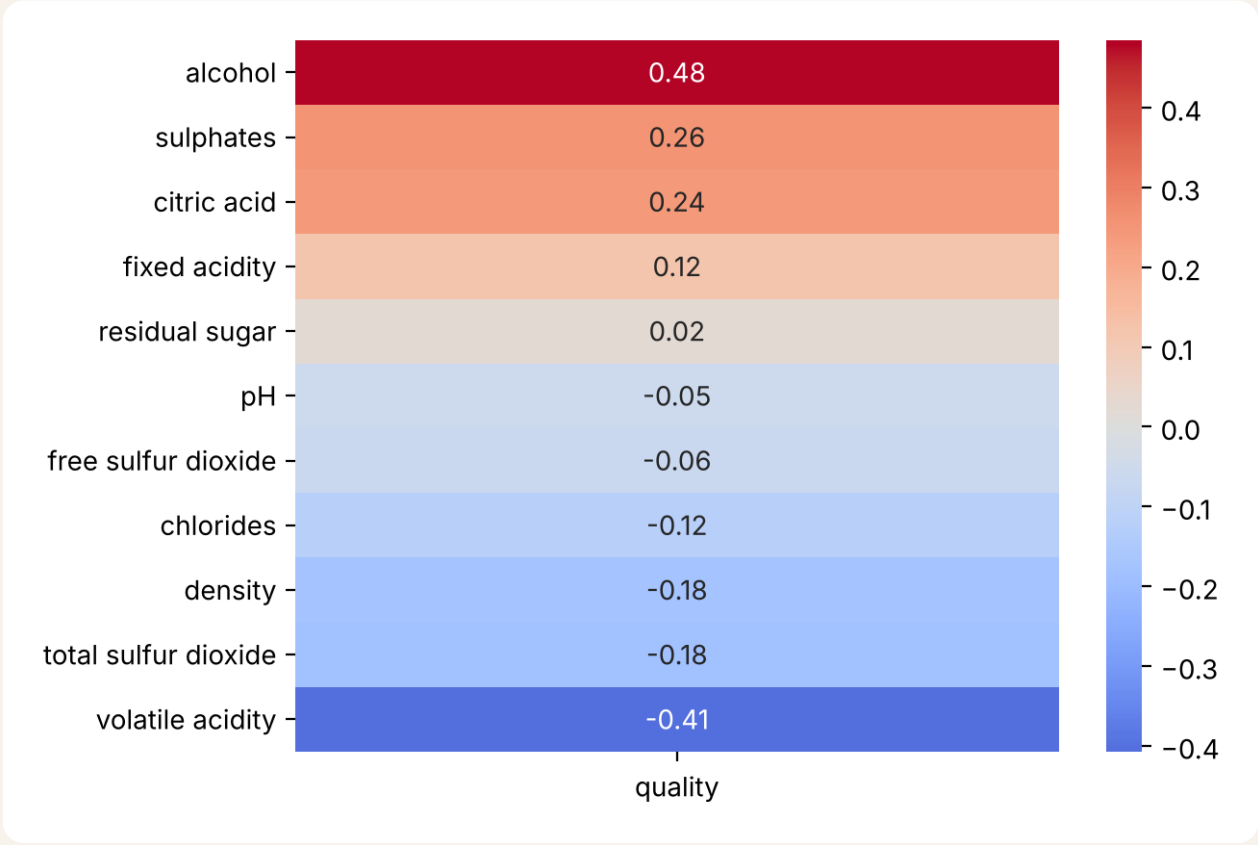
↑ Mais sulfatos
conservante em maior nível nos bons

Quebra de expectativa: o açúcar residual é quase igual nos dois grupos: doçura não define qualidade.

No gráfico: 0 = baixa ou média qualidade · 1 = alta qualidade

02 · EXPLORAÇÃO DOS DADOS

Álcool sobe com a nota; acidez volátil desce



+0,48

Álcool: o sinal positivo mais forte

−0,41

Acidez volátil: o sinal negativo mais forte

0,02

Açúcar residual: praticamente nenhuma relação

A densidade (−0,18) aparece porque acompanha o álcool: vinhos mais alcoólicos são menos densos.

Nenhuma medida passa de 0,5 sozinha: **a qualidade vem da combinação de vários fatores**

03.
PREPARAÇÃO & MODELOS



03 · PREPARAÇÃO & MODELOS

Como preparamos um teste justo

1

Prova com vinhos inéditos

914 vinhos para aprender e 229 guardados para a prova final, com a mesma proporção de vinhos bons.

2

Mesma escala em todas as medidas

Padronizamos as medidas, que estão em escalas muito diferentes.

3

Mais peso aos vinhos bons

Só 14% dos vinhos são bons. Errar um deles conta mais no treino, para o modelo não ignorá-los.

4

“Doçura” ficou de fora

Usar a doçura como variável não ajudaria: de 92% a 99,5% dos vinhos são “secos”.

6 modelos: Random Forest, SVM, Regressão Logística, Naive Bayes, KNN e Árvore de Decisão.

Validação cruzada: cada um foi testado 5 vezes com partes diferentes da base, para o resultado não depender de sorte

03 · OS MODELOS

Métricas completas dos 6 modelos

Métrica	Random Forest	SVM	Regressão Logística	Naive Bayes	KNN	Árvore de Decisão
Acurácia	88%	82%	80%	84%	87%	88%
Precisão	57%	41%	38%	45%	52%	56%
Recall	63%	72%	69%	59%	44%	56%
F1	60%	52%	49%	51%	48%	56%
ROC-AUC (teste)	91%	87%	85%	81%	83%	75%
ROC-AUC (validação cruzada)	**94%**	**89%**	**87%**	**85%**	**84%**	**73%**

Como escolhemos: pelo ROC-AUC, a chance de o modelo colocar um vinho bom à frente de um mediano (50% seria chute, 100% seria perfeito)

Usamos a média de 5 rodadas de teste, para não depender de sorte. **Random Forest (94%) e SVM (89%) lideraram.**

03 · PREPARAÇÃO & MODELOS

Random Forest: mais acertos, menos erros

Métrica	O que mede	SVM	Random Forest
Acurácia	Acertos no total	82%	**88%**
Precisão	Dos que o modelo chamou de bons, quantos eram	41%	**57%**
Recall	Dos bons de verdade, quantos o modelo encontrou	**72%**	63%
F1	Média entre Precisão e Recall	52%	**60%**
ROC-AUC	Capacidade de ranquear bons acima dos medianos	87%	**91%**
Erros totais	Alarmes falsos + Vinhos bons perdidos	42	**27**

O Random Forest vence em 5 das 6 métricas; o SVM só leva no recall.

Uso: Random Forest para decisões em que errar custa caro (menos erros e 57% de Precisão); SVM como triagem, para não deixar passar vinhos bons (72% de Recall).

Métricas no conjunto de teste (229 vinhos) · precisão, recall e F1 da classe alta qualidade

03 · PREPARAÇÃO & MODELOS

Por que Random Forest e SVM se saíram melhor?

Random Forest · 300 provadores que votam

- Uma árvore de decisão é uma sequência de perguntas: o álcool passa de 11? A acidez volátil é baixa?
- O Random Forest monta 300 árvores diferentes e decide pela maioria: os erros de cada uma se anulam.
- Uma árvore sozinha: 73% de ROC-AUC. As 300 juntas: 94%.

SVM · uma divisória flexível

- Imagine os vinhos num gráfico: o SVM traça uma divisa entre bons e medianos.
- Essa divisa pode ser curva e contornar o grupo dos bons, mesmo misturado aos medianos.
- Foi o que mais encontrou vinhos bons: 72%.

Por que os outros ficaram atrás

Regressão Logística: só traça divisórias retas.

Árvore de decisão: é uma árvore só, não 300.

Naive Bayes: supõe medidas independentes, mas vimos que várias andam juntas.

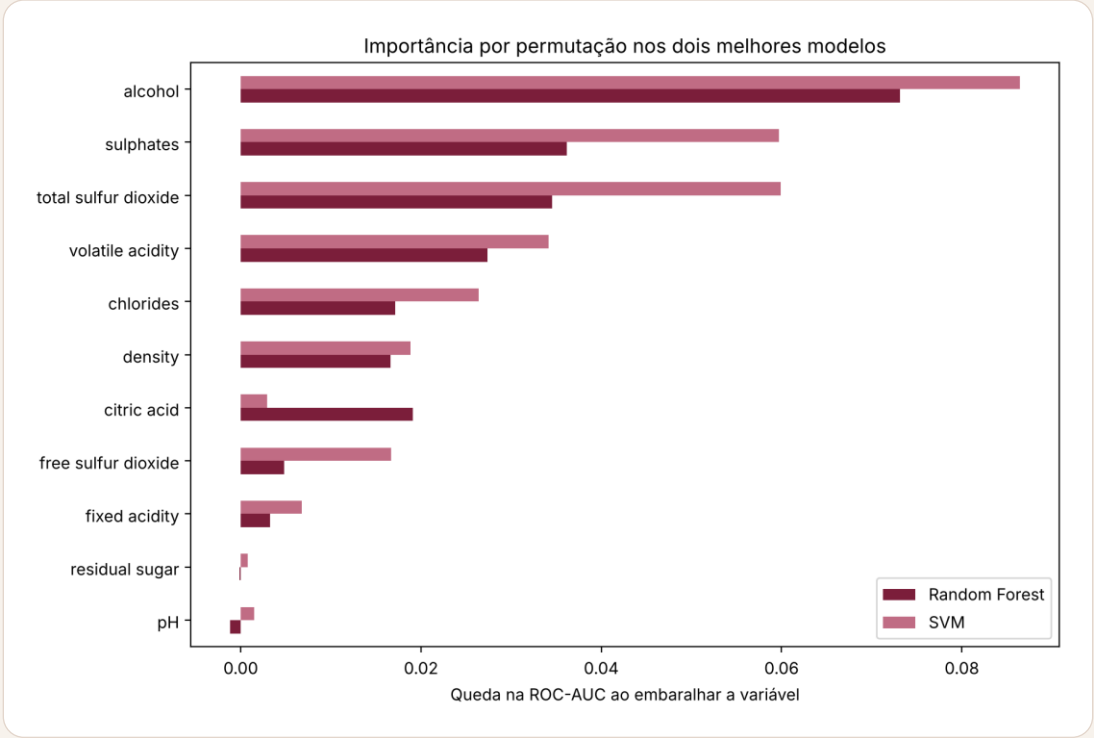
KNN: segue os vizinhos, mas 86% são vinhos medianos, então quase não detecta os bons.

04.
CONCLUSÕES



04 · CONCLUSÕES

Os dois modelos concordam: quatro medidas pesam mais



Queda em pontos

Medida	Random Forest	SVM
Álcool	7,3	8,6
Sulfatos	3,6	6,0
SO_2 total	3,5	6,0
Acidez volátil	2,7	3,4

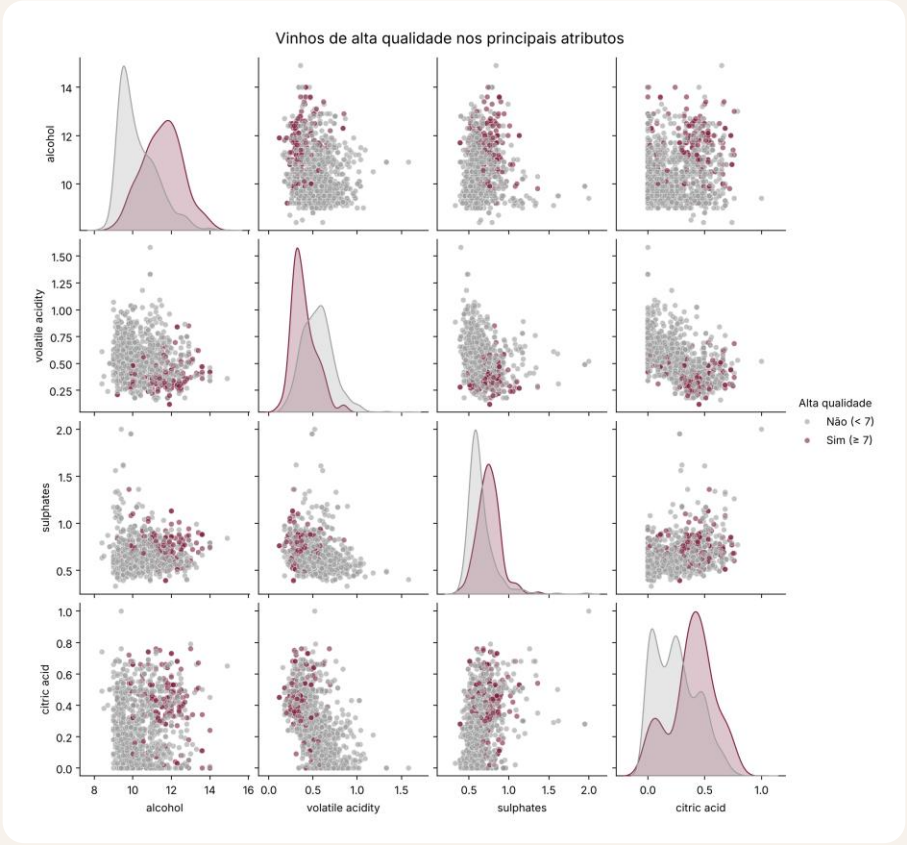
Ácido cítrico, que se destacava nos boxplots, quase não pesa nos modelos: parte da informação dele já está na acidez fixa.

Açúcar residual e pH: importância praticamente nula.

Como medimos: embaralhamos os valores de uma medida e vemos quanto o modelo piora (quanto mais piora, mais ele depende dela).

04 · CONCLUSÕES

Chances de escolher um vinho de alta qualidade



14%

entre todos os vinhos

↓

34%

entre vinhos com álcool ≥ 11

↓

46%

entre vinhos com **álcool ≥ 11** e **acidez volátil < 0,5**.

Nenhuma medida sozinha diz se um vinho é bom; quanto mais medidas combinamos, melhor conseguimos separar.

E é por isso que precisamos de um modelo.

04 · CONCLUSÕES

Do achado à prática: nossas recomendações

O que descobrimos	O que recomendamos
Álcool é o sinal mais forte nos dois modelos	Usar o teor alcoólico como indicador central do potencial de qualidade — nunca isolado
Acidez volátil alta derruba a nota	Reforçar o controle sanitário e de oxidação durante a vinificação
Sulfatos maiores e SO_2 total menor nos vinhos bons	Acompanhar a dosagem dos conservantes, pensando na qualidade e não só na conservação
Açúcar residual e pH quase não pesam	Dar baixa prioridade a ajustes finos nessas medidas
As medidas atuam em conjunto	Avaliar o vinho com o modelo: Random Forest quando errar custa caro; SVM na triagem, para não perder vinhos bons

O modelo apoia a decisão (por exemplo, priorizar lotes para a prova), sem substituir a avaliação dos especialistas

EM UMA FRASE

A qualidade do vinho vem de uma combinação química, e o Machine Learning consegue lê-la a partir do laboratório.

94%
ROC-AUC na validação cruzada

88%
de acerto no teste

4
medidas que mais pesam na qualidade

Cuidados: associação não é causa · base pequena (32 vinhos bons no teste) · só vinhos tintos

Obrigado!

Integrantes:

- Félix (RM376964)
- Guilherme (RM377456)
- João Victor (RM376205)
- Rafael (RM376323)

Video da apresentação

https://www.youtube.com/watch?v=UniWBKFUetw

Link do repositório

https://github.com/JoaoVictorOliveiraSe/Tech_challenge_fiap_fase2.git